



GRENOBLE ALPES RECHERCHE

INFRASTRUCTURE DE

CALCUL INTENSIF

ET DE DONNÉES

La synergie grenobloise

Frédéric Desprez (Grid'5000), Violaine Louvet (GRICAD)



Le contexte grenoblois

- Projet CIMENT depuis 1998
- Fusion des universités, IDEX
- Engagement fort des établissements vers la mutualisation des ressources : datacentre, plateformes (stockage, cloud)
- Unité de lieux des laboratoires du numérique
- Communauté soudée qui a l'habitude de décloisonner et de travailler ensemble sur des projets communs



Grid'5000 : instrument scientifique national

- « A **large-scale** and **versatile** testbed for **experiment-driven research** in all areas of computer science, with a focus on parallel and distributed computing including **Cloud, HPC and Big Data** »

- Plate-forme **nationale** et **distribuée** structurée en Groupement d'Intérêt Scientifique (**GIS**)

- CNRS, Inria, CEA, CPU, CDEFI, IMT, Renater
 - Implication des **scientifiques sur chaque site**
 - Une équipe technique : **5-8 ingénieurs répartis sur les sites**
 - **LIG acteur majeur de la plate-forme** (pilotage, design, logiciels, utilisateurs)



- Une communauté d'utilisateurs **nationale et internationale**

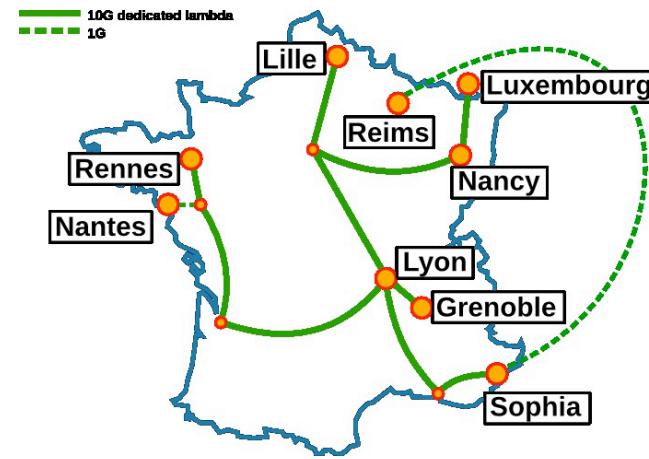
- Ouvert à **tous les partenaires académiques** depuis 2006
 - Depuis fin 2013 : programme « **open access** »
 - 2 825 utilisateurs au total depuis 2005, 1 099 comptes actifs sur les 3 dernières années, 532 comptes actifs sur les 12 derniers mois
 - > 1 401 publications, environ 30 HDRs et thèses par an
 - 7 473 153 réservations de ressources, pour 32 100 cœur.années, 549 016 réservations ; 4 988 cœur.années sur les 12 derniers mois

- Une **renommée internationale**

- USA : projets NSF inspirés de Grid'5000 (Chameleon cloud)
 - Ainsi qu'au Luxembourg, Brésil, Colombie, Portugal, ...

Grid'5000 : une plateforme expérimentale

- Infrastructure de grande échelle et mutualisée
- Une plate-forme nationale
 - 8 sites avec interconnexion dédiée (10Gbps)
 - 8000 cœurs (1000 nœuds)
 - 500+ utilisateurs actifs chaque année
 - Des clusters thématiques : HPC, Cloud, BigData



- Reconfigurabilité et contrôle
 - L'utilisateur déploie sa propre plate-forme ! (**Hardware-aaS**)
 - Expérience sur toutes les couches logicielles
 - Isolation/reconfiguration réseau
 - Monitoring (performance, énergie)
 - Traçabilité de la plate-forme
 - Orchestration d'expérience



→ L'utilisateur déploie sa propre pile HPC, Cloud ou Big-Data !

Grid'5000 – travaux en cours et futurs

- **Calcul à hautes performances**

- Relations avec des fonctionnalités hardware particulières et combinaisons CPU/réseau
- Nouveaux stockages (SSD)
- nouvelles fonctionnalités matérielles (manycore, hyperthreading, burst mode, ...)

- **Clouds et virtualisation**

- Virtualisation du réseau (Impact des SDNs)
- Virtualisation du stockage
- Piles logicielles Clouds disponibles pour les développeurs d'applications
- Injection de traces réelles (workloads, fautes)

- **Gestion de l'énergie**

- Monitoring de l'énergie des infrastructures virtualisées
- Besoin d'avoir des architectures hétérogènes (GPU, ARM)

- **Gestion de grandes masses de données**

- MapReduce, Workflows
- Problématiques de stockage liées au HPC

- **Recherche reproductible**

- Description et vérification de l'environnement expérimental
- Améliorer le contrôle et la description des expérimentations

GRICAD

- **Unité Mixte de Service**, création au **1er janvier 2016**
- **Tutelles** : CNRS, Université Grenoble Alpes, Grenoble-INP.
 - Liens avec l'INRIA et le CEA
- **Partenariats forts** avec tous les acteurs du site : DSU UGA et G-INP, SIMSU, laboratoires, composantes d'enseignements
- **Porteur des projets d'infrastructures numériques mutualisées** du site : coordination et pilotage en mutualisant les compétences et les expertises présentes



- **Modèle organisationnel mixte**
 - Personnels rattachés à la structure et personnels des unités, services communs et composantes investis à temps partiel dans les projets.
 - Favorise la proximité avec les équipes de recherche, facteur de montée en compétence.

GRICAD : Missions

- **Missions autour du calcul intensif**

- Gestion des plateformes de calcul et de traitement intensif et accompagnement des utilisateurs.

- **Missions d'infrastructures de base en co-pilotage avec les structures partenaires**

- Gestion des salles des datacentres mutualisés du site grenoblois, hébergement, réseaux

- **Missions autour des données**

- Gestion des infrastructures mutualisées de stockage, de diffusion et de sauvegarde.
- Support aux utilisateurs sur tout le cycle de vie de la donnée.

- **Missions d'infrastructures et de services**

- Administration des services à valeur ajoutée pour la recherche : forge logicielle,bases de données...

- **Missions d'expertises, de réseautage et de soutien**

- Réseau de compétences.
- Veille technologique et expérimentation.
- Support au montage de projets nationaux ou européens sur la partie technique.

CIMENT : plateforme de calcul grenobloise

Platforms of the HPC center of the University of Grenoble

CiGri lightweight computing grid

OAR batch scheduler

HPC platform

Froggy



3200 Xeon E5 cores @2.6Ghz
+18 GPUs K20m

High performance distributed storage (Lustre): 90 TB
Infiniband FDR network
Remote visu nodes

OAR batch scheduler

Data processing platform



Luke



~400 cores - heterogeneous systems
and continuously evolving



Local scratches on nodes
450 TB



10 Gbe network
Remote visu nodes

OAR batch scheduler

Other thematic platforms

~3000 cores heterogeneous systems
federated from 10 clusters of
member laboratories



NFS filesystems:
a few TB per cluster



Infiniband QDR network

7068 cores
132 Tflops
1.4 PBytes

Pilotage par les chercheurs

Organisation en **pôles** par
domaine scientifique

Correspondants dans les labos

Groupe Opérationnel mettant à
contribution les ingénieurs des
labos



Common distributed storage (IRODS) 1Po

Accès souple :

Ouverture de comptes utilisateurs et création de projets **au fil de l'eau**

Partage des ressources pragmatique

Accès via un gestionnaire de tache (batch scheduler)

Intégration de ressources dédiées (labo) avec **partage en mode grille / best-effort**

Administration mutualisée

Communauté et formations

Partenariat avec **MaiMoSINE**

Journée annuelle des utilisateurs, séminaires
labo

Formation école doctorale, groupe calcul
grenoblois

2 plateformes complémentaires

  		
Objectif général	Contribution à la recherche informatique <i>«L'objectif est la méthode »</i>	Calcul Scientifique <i>«L'objectif est le résultat »</i>
Communauté utilisateurs	Recherche informatique « et + si affinité » Plate-forme nationale	Toutes les disciplines scientifiques Plate-forme régionale
Domaines d'expérimentation	Multiples : HPC, Cloud, Big Data... Informatique distribuée au sens large	Calcul Intensif, traitement intensif (cas d'usage classiques)
Particularité de l'Infrastructure	« Expérimentation » Contrôle, traçabilité, reconfigurabilité, interactivité	« Production » Optimisée pour la puissance de calcul, traitement par lot

Challenges Grid'5000 VS Mésocentre

- **Expérimentation VS Production**
- **Finalité:** objectif méthode VS résultat
 - pas besoin de Walltime aussi long pour l'expérimentation
- **Interactivité:** traitement batch difficile pour l'expérimentation (réservation à l'avance)
 - Difficulté de scripter des environnements complexes et d'avant garde/instables
 - Gros effort pour l'instrumentation des expériences (reproductibilité), mais plus complexe qu'un script HPC classique
- **Traçabilité de la plateforme:** pour la reproductibilité de l'expérimentation, il est important de garder les logs des modifications de l'infrastructure VS production vise surtout la justesse du résultat
 - **Evolution :** production scientifique et non industrielle -> plus proche de l'expérimentation
- **Communauté:** informaticien VS tout domaine scientifique
 - culture différente: l'informaticien veut des fonctionnalités en avance VS le physicien veut son résultat !
- **Environnement applicatif:** la plateforme d'expérimentation est « nue » VS l'utilisateur HPC production s'attend à avoir un environnement application clé en main (modules & co)

Challenges Grid'5000 VS Mésocentre

- **Expérimentation Cloud&co VS Expérimentation HPC**

- Déploiement *bare metal* nécessaire pour des expériences bas niveau sur le système
 - bcp plus commun pour la communauté cloud que la communauté HPC
 - le Cloud met en avant les "couches systèmes" et "Linux", alors que le HPC essaie historiquement plutôt de cacher la couche système (Appli <-> hardware)
- Machines Virtuelles essentielles pour le cloud VS superflues pour le HPC
 - mais les containers arrivent dans le monde du HPC (l'utilisateur vient avec son environnement d'exécution)
- Modification du réseau (kavlan) inutile pour le HPC ?
 - cela arrive maintenant aussi pour le HPC (SC16: SDN Infiniband, modification du routage/job)
- Description de la plateforme interrogeable de manière programmatique
 - nécessaire pour un datacentre expérimental cloud (introspection, etc), moins pour HPC: on joue moins avec la plate-forme, on part du principe qu'un cluster est installé à l'achat et évolue peu.
- Environnement applicatif: pile BigData/etc vs pile HPC (modules), mais ça converge !

Synergies : Dev & Admin



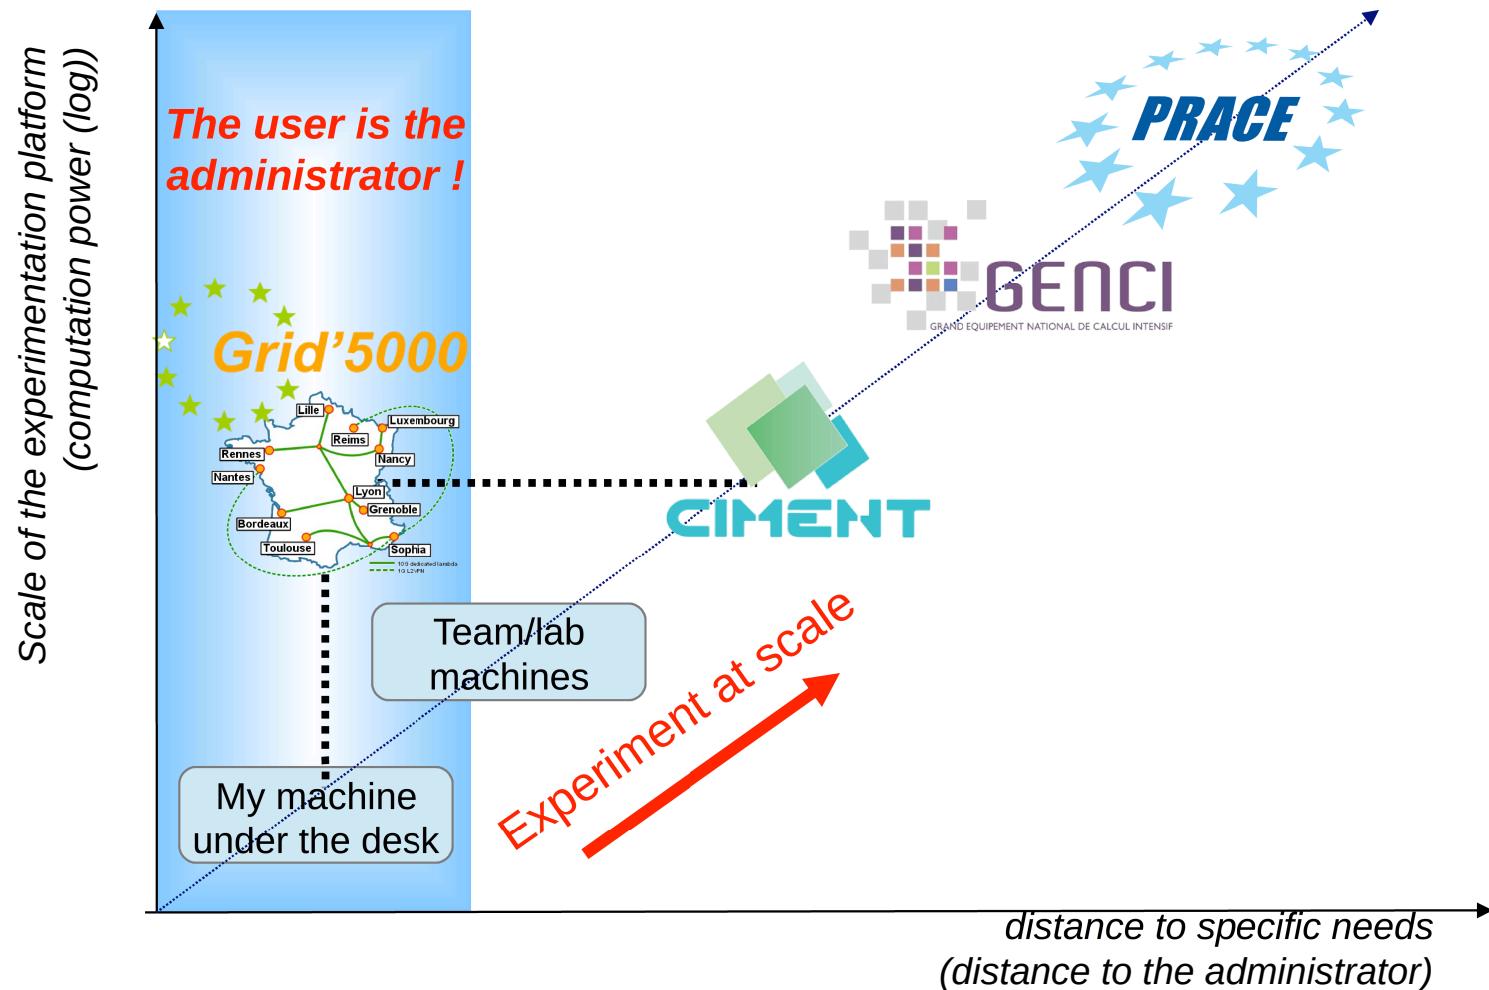
- **Développements communs :**

- Contribution des 2 plateformes au développement de OAR (REST API, module hulot/energy saving)
- CIGRI (développement commun de la version 3)
- COLMET : profiling système des jobs

- **Mutualisation des compétences administrateurs**

- Expertise croisées sur les matériels/achats
- Gestion d'infrastructure (services)
- Bonnes pratiques pour la gestion des utilisateurs
- Expertise HPC

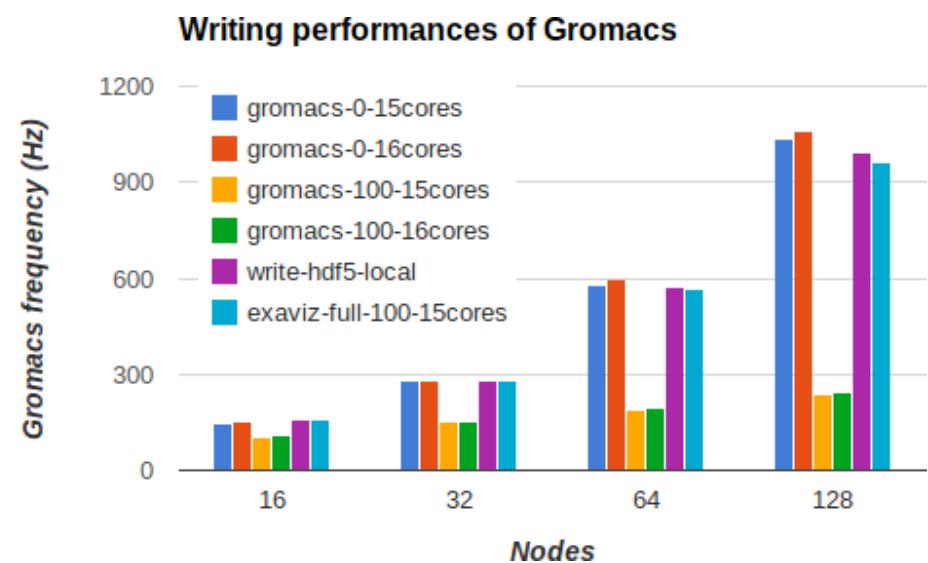
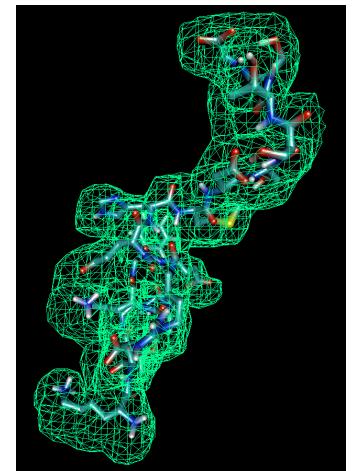
Synergies : Expérimentation HPC



Passage à l'échelle : complémentarité des plateformes

Un exemple de la complémentarité

- Travaux B. Raffin - **HPC: In Situ Analytics**
- **But:** mieux organiser les phases de simulation et d'analyse de données
- Simuler sur un cluster; déplacer les données; analyse post-mortem
 - Inadapté à l'Exascale (volume des données, temps)
- **Solution:** analyser sur les nœuds, pendant la simulation
 - Entre ou pendant les phases de simulation ? cœur ou nœud dédié ?
- **Grid'5000** utilisé pour le développement et les tests, car contrôle:
 - De l'environnement logiciel (piles MPI)
 - Des paramètres CPU (Hyperthreading)
 - Des paramètres réseaux (QoS Infiniband)
- Puis évaluation du passage à l'échelle sur le supercalculateur Froggy (**CIMENT**)



Perspectives

- Convergence des plateformes
 - un pas de plus pour la mutualisation des financements matériels et des efforts humains ...
 - pas nouveau + nouveaux challenges pour aller + loin ! (notamment quels arbitrages entre les usages différents "Expérimentation informatique " VS "prod HPC tout domaine")
- Mésocentre/G5K = plateforme expérimentale HPC ?
- Enfin une machine dimensionnante dans Grid'5000 ?
 - 1 machine de plusieurs milliers de coeurs ?
- Une plateforme BDEC (*Big Data Extreme Computing* <http://www.exascale.org/bdec/>) ?
 - NVM - Storage Class Memory

Perspectives

- Contributions actives dans des communautés internationales : IRODS, NIX
- Evolution des solutions de traitement de la donnée
- Nouvelle plateforme robuste aux I/O intensifs : convergence avec le besoin de machine big-data/burst buffers de g5k@grenoble
- Utilisateurs demandeurs d'outils de 'cloud léger' pour tout ce qui concerne les applications de traitement intensif (avec la problématique de la gestion des ressources de stockage) : aller plus loin avec CIGRI ?
- Serveur de notebooks, projet UGA 2.0 (recherche) et projets en enseignement

Merci de votre attention

Questions ?

Remerciements à **Bruno Bzeznik** (responsable pôle calcul de GRICAD), **Emmanuel Chaljub** (responsable scientifique CIMENT), **Pierre Neyron** (g5k@Grenoble), **Olivier Richard** (g5k@Grenoble)